

# table traine**R**

## Workouts für {data.table}



zusammengestellt von  
Prof. Dr. Jörg große Schlarmann



Version vom 16.10.2024

# Lizenz

## Willkommen beim Table Training!

In diesem Buch sind zahlreiche Übungen zur freien Statistiksoftware R enthalten, die sich ausschließlich mit dem Paket `{data.table}` befassen.



Dieses Script ist unter der Creative Commons BY-NC-SA 4.0<sup>1</sup> lizenziert.

Sie dürfen:

- **Teilen** — das Material in jedwedem Format oder Medium vervielfältigen und weiterverbreiten.
- **Bearbeiten** — das Material remixen, verändern und darauf aufbauen.

Unter folgenden Bedingungen:

- **👤 Namensnennung** — Sie müssen angemessene Urheber- und Rechteangaben machen, einen Link zur Lizenz beifügen und angeben, ob Änderungen vorgenommen wurden. Diese Angaben dürfen in jeder angemessenen Art und Weise gemacht werden, allerdings nicht so, dass der Eindruck entsteht, der Lizenzgeber unterstütze gerade Sie oder Ihre Nutzung besonders.
- **🚫 Nicht kommerziell** — Sie dürfen das Material nicht für kommerzielle Zwecke nutzen.
- **🔄 Weitergabe unter gleichen Bedingungen** — Wenn Sie das Material remixen, verändern oder anderweitig direkt darauf aufbauen, dürfen Sie Ihre Beiträge nur unter derselben Lizenz wie das Original verbreiten.

**Keine weiteren Einschränkungen** — Sie dürfen keine zusätzlichen Klauseln oder technische Verfahren einsetzen, die anderen rechtlich irgendetwas untersagen, was die Lizenz erlaubt.

### 💡 Zitationsvorschlag

große Schlarmann, J (2024): “table traineR. Workouts für `{data.table}`”, <https://www.produnis.de/tabletrainer/>

```
@book{grSchl_tabletrainer,  
  author = {{große Schlarmann}, Jörg},  
  title = {{table traineR}. Workouts für \{data.table\}},  
  year = {2024},  
  publisher = {Hochschule Niederrhein},  
  address = {Krefeld},  
  copyright = {CC BY-NC-SA 4.0},  
  url = {https://www.produnis.de/tabletrainer/},  
  language = {de},  
}
```

<sup>1</sup>siehe <https://creativecommons.org/licenses/by-nc-sa/4.0/>

# Inhaltsverzeichnis

<b>Lizenz</b>	<b>i</b>
<b>Inhaltsverzeichnis</b>	<b>ii</b>
<b>1. Einleitung</b>	<b>1</b>
1.1. Vorbereitungen . . . . .	1
<b>2. Kurze Einführung in {data.table}</b>	<b>3</b>
2.1. Installation . . . . .	3
2.2. Modify-in-Place . . . . .	3
2.3. Grundlegende Syntax . . . . .	4
2.4. Daten einlesen . . . . .	4
2.5. Daten speichern . . . . .	5
2.6. Fälle filtern mit i . . . . .	6
2.7. Fälle sortieren mit i . . . . .	7
2.8. Daten verarbeiten mit j . . . . .	8
2.9. Daten bearbeiten mit j . . . . .	9
2.10. data.table kopieren . . . . .	10
2.11. pipen . . . . .	12
2.12. Ergebnisse gruppieren mit by . . . . .	13
2.13. Weitere Funktionen aus dem data.table Paket . . . . .	15
2.13.1. Einzigartige bestimmen mit uniqueN . . . . .	15
2.13.2. Anzahl der Fälle mit .N . . . . .	15
2.13.3. Lange Tabelle erzeugen mit melt() . . . . .	16
2.13.4. Breite Tabelle erzeugen mit dcast() . . . . .	18
<b>I. Aufgaben</b>	<b>19</b>
<b>3. Aufgaben</b>	<b>20</b>
3.1. Aufgabe 3.1 Größe und Gewicht . . . . .	20
3.2. Aufgabe 3.2 Datentabelle . . . . .	21
3.3. Aufgabe 3.3 Big Five . . . . .	22
3.4. Aufgabe 3.4 Rolling Stone Magazine . . . . .	22
<b>II. Lösungswege</b>	<b>24</b>
<b>4. Lösungswege</b>	<b>25</b>
4.1. Lösung zur Aufgabe 3.1 Größe und Gewicht . . . . .	25
4.2. Lösung zur Aufgabe 3.2 Datentabelle . . . . .	27
4.3. Lösung zur Aufgabe 3.3 Big Five . . . . .	32
4.4. Lösung zur Aufgabe 3.4 Rolling Stone Magazine . . . . .	34
<b>Literaturverzeichnis</b>	<b>43</b>

**Credits**

**44**

# 1. Einleitung

“You shouldn’t feel ashamed about your code - if it solves the problem, it’s perfect just the way it is. But also, it could always be better.” — **Hadley Wickham** at `rstudio::conf2019`

## Willkommen zum Table Training!

In diesem Buch sind zahlreiche Übungen zur freien Statistiksoftware R enthalten, die sich ausschließlich mit dem Paket `{data.table}` befassen. Dafür werden Grundkenntnisse in R und RStudio vorausgesetzt.

Sollten Sie neu in R sein, ist diese Aufgabensammlung wahrscheinlich nicht für Sie geeignet. Viel mehr könnte Ihnen das freie Nachschlagewerk von große Schlarmann (2024c) einen niederschweligen Einstieg in R ermöglichen.



Wenn Sie schon erste Schritte in R und dem `tidyverse` gegangen sind, können Sie nun versuchen, Ihre Lösungsstrategien mit `{data.table}` umzusetzen. Lassen Sie sich nicht entmutigen, R hat eine steile Lernkurve, und nur durch Übung kommen Sie weiter. Diese Sammlung möchte Sie auf Ihrem Weg begleiten und Sie befähigen, *typische* Aufgaben in R sicher mit `{data.table}` zu meistern.

Der Quelltext dieses Buchs ist bei GitHub verfügbar, siehe <https://github.com/produnis/tabletrainer>.

- Eine aktuelle epub-Version finden Sie unter:  
<https://www.produnis.de/tabletrainer/tabletraineR.epub>
- Eine aktuelle PDF-Version finden Sie unter:  
<https://www.produnis.de/tabletrainer/tabletraineR.pdf>
- Kritik und Diskussion sind per Mastodon möglich:  
<https://mastodon.social/@rbuch>

## 1.1. Vorbereitungen

Falls Sie **RStudio** verwenden, legen Sie sich ein eigenes Projekt `tabletraineR` für die Übungen an.

Dies hat den Vorteil, dass alle Dateien in einem Ordner gesammelt vorhanden sind. Um Ihre Datensätze von Ihren Scriptdateien zu separieren, empfiehlt es sich, einen `data`-Ordner anzulegen, in welchem alle Datensätze gespeichert werden können (Abbildung 1.1).

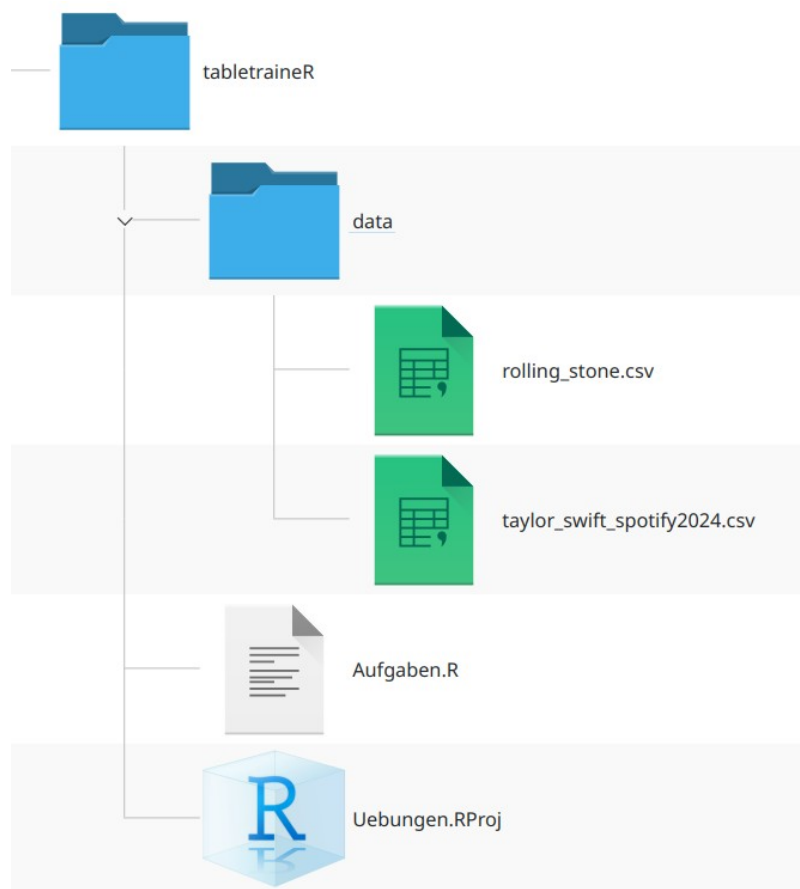



Abbildung 1.1.: beispielhafte Ordnerstruktur

## 2. Kurze Einführung in {data.table}

Neben dem tidyverse steht mit `data.table` ein weiterer R-Dialekt zur Verfügung, der sich immer größerer Beliebtheit erfreut. Im Kern sind `data.tables` verbesserte Versionen von `data.frames`, die schneller und speichereffizienter arbeiten und mit einer prägnanteren Syntax manipuliert werden können. Das Paket stellt außerdem eine Reihe zusätzlicher Funktionen zum Lesen und Schreiben von tabellarischen Dateien, zum Umformen von Daten zwischen langen und breiten Formaten und zum Verbinden von Datensätzen zur Verfügung.



### 2.1. Installation

Alle Funktionen sind über das Paket `data.table` implementiert, welches wie gewohnt installiert und aktiviert werden kann.

```
# installiere data.table
install.packages("data.table", dependencies=TRUE)
```

```
# data.table aktivieren
library(data.table)
```

### 2.2. Modify-in-Place

Der größte Unterschied besteht darin, dass `data.table` die *Modify-in-Place*-Methode verwendet. Das klassische R und auch das Tidyverse verwenden die *Copy-on-Modify*-Methode, welche besagt, dass bei der Manipulation eines Objektes das Ergebnis in einem neuen Objekt gespeichert wird.

```
# klassisches "Copy-on-Modify"
meine.daten %>%
  mutate(Neu = Alt*10)
```

Bei oben stehendem Code wird das Objekt `meine.daten` nicht verändert. Das Ergebnis der `mutate()`-Funktion wird als neues Objekt ausgegeben. Dieses neue Objekt ist eine Kopie der Ursprungsdaten `meine.daten`, an welcher die Veränderungen vorgenommen werden.

Mit `data.table` wird der Ansatz *Modify-in-Place* verfolgt.

```
# Modify-in-Place
meine.daten[, Neu := Alt*10]
```

Der oben stehende Code erzeugt keine Kopie von `meine.daten`. Vielmehr wird das Objekt `meine.daten` **direkt** verändert. Im klassischen R entspricht diese Vorgehensweise dem Code

```
meine.daten$Neu <- meine.daten$Alt*10
```

Durch *Modify-in-Place* wird `data.table` sehr effizient, wenn größere Datenmengen verarbeitet werden sollen. Es kann jedoch auch dazu führen, dass der Code schwieriger zu verstehen ist und überraschende Ergebnisse liefert (insbesondere, wenn ein `data.table` innerhalb einer Funktion modifiziert wird).

## 2.3. Grundlegende Syntax

Die generelle Syntax von `data.table` lautet

```
dt[i, j, by]
```

wobei

- `dt` ein `data.table`-Objekt ist.
- `i` zum Filtern und für `join`-Funktionen genutzt wird.
- `j` zum Manipulieren, Transformieren und Zusammenfassen der Daten verwendet wird.
- `by` zum Gruppieren genutzt wird.

Man kann die Syntax lesen als:

„In diesen Zeilen, mache dies, gruppiert nach jenem“.

## 2.4. Daten einlesen

Der erste Schritt der meisten Datenanalysen besteht darin, Daten in den Speicher zu laden. Wir können die Funktion `data.table::fread()` verwenden (das `f` steht für *fast* (schnell)), um reguläre, durch Trennzeichen getrennte Dateien wie `txt`- oder `csv`-Dateien zu lesen. Diese Funktion ist nicht nur schnell, sondern erkennt automatisch das Trennzeichen und errät die Klasse jeder Spalte sowie die Anzahl der Zeilen in der Datei.

```
# Daten einlesen mit fread()
dt <- fread("data/Befragung22.csv")

# anschauen
str(dt)
```

```
Classes 'data.table' and 'data.frame': 37 obs. of 6 variables:
 $ alter      : int  20 28 41 34 26 38 28 21 27 26 ...
 $ geschlecht: chr   "weiblich" "weiblich" "männlich" "weiblich" ...
 $ stifte     : int  12 7 1 13 18 25 29 1 2 5 ...
 $ geburtsort: chr   "Düren" "Neuss" "Bonn" "Düsseldorf" ...
 $ fahrzeit   : int  1 45 60 25 15 50 40 60 60 40 ...
 $ podcast    : chr   "selten" "selten" "selten" "oft" ...
 - attr(*, ".internal.selfref")=<externalptr>
```

Das Objekt `dt` gehört sowohl zur Klasse `data.frame` als auch zu der neuen Klasse `data.table`.

Die Daten können auch direkt über eine URL eingelesen werden.



```
# lade per URL
dt <- fread("https://www.produnis.de/tabletrainer/data/Befragung22.csv")
```

Liegen die Daten bereits als `data.frame` vor, können sie per `as.data.table()` umgewandelt werden.

```
# lade klassisches Datenframe
df <- read.table("https://www.produnis.de/tabletrainer/data/Datentabelle.txt",
                 header=TRUE)

# wandle in data.table um
dt2 <- as.data.table(df)
```

```
Classes 'data.table' and 'data.frame': 10 obs. of 4 variables:
 $ Geschlecht: chr "m" "w" "w" "m" ...
 $ Alter      : int 28 18 25 29 21 19 27 26 31 22
 $ Gewicht    : int 80 55 74 101 84 74 65 56 88 78
 $ Groesse    : int 170 174 183 190 185 178 169 163 189 184
 - attr(*, ".internal.selfref")=<externalptr>
```

Sollen die Daten von Hand eingegeben werden, wird die Funktion `data.table()` verwendet.

```
# erzeuge von Hand
dt3 <- data.table(x = 1:10,
                  y = 11:20,
                  z = factor(rep(c("foo", "bar"), 5))
                  )

# anschauen
str(dt3)
```

```
Classes 'data.table' and 'data.frame': 10 obs. of 3 variables:
 $ x: int 1 2 3 4 5 6 7 8 9 10
 $ y: int 11 12 13 14 15 16 17 18 19 20
 $ z: Factor w/ 2 levels "bar","foo": 2 1 2 1 2 1 2 1 2 1
 - attr(*, ".internal.selfref")=<externalptr>
```

## 2.5. Daten speichern

Mit der Funktion `fwrite()` können `data.tables` (aber auch `data.frames`) in eine Datei gespeichert werden. Sie funktioniert ähnlich wie `write.csv`, ist aber wesentlich schneller. Wird kein Dateiname angegeben, erfolgt die Ausgabe in der Konsole. So kann überprüft werden, was in die Datei geschrieben würde.

```
# schreibe Objekt "dt2" in die Konsole
fwrite(dt2)
```

```
Geschlecht,Alter,Gewicht,Groesse
m,28,80,170
w,18,55,174
w,25,74,183
```

```

m,29,101,190
m,21,84,185
w,19,74,178
w,27,65,169
w,26,56,163
m,31,88,189
m,22,78,184

```

```

# schreibe Objekt "dt" in datei "dt.csv"
fwrite(dt2, "dt2.csv")
# schreibe Objekt "dt" in datei "dt.txt"
fwrite(dt2, "dt2.txt")

```

## 2.6. Fälle filtern mit `i`

Wir erinnern uns, dass die allgemeine Syntax `dt[i, j, by]` lautet. Über den Parameter `i` können die Daten gefiltert werden, so dass nur bestimmte Fälle berücksichtigt werden. Beispielsweise könnten wir im Objekt `dt` nur solche Fälle auswählen, bei denen das Alter größer als 30 ist.

```
dt[alter > 30]
```

	alter	geschlecht	stifte	geburtsort	fahrzeit	podcast
	<int>	<char>	<int>	<char>	<int>	<char>
1:	41	männlich	1	Bonn	60	selten
2:	34	weiblich	13	Düsseldorf	25	oft
3:	38	weiblich	25	Dinslaken	50	oft
4:	38	männlich	5	Donezk	57	manchmal
5:	31	weiblich	16	Charkov Ukraine	135	oft
6:	36	weiblich	1	Rybnik	90	manchmal
7:	45	männlich	1	Gelsenkirchen	85	oft

Dies ist Vergleichbar mit dem klassischen R-Aufruf

```

# klassischer R-Befehl
dt[dt$alter > 30]

```

	alter	geschlecht	stifte	geburtsort	fahrzeit	podcast
	<int>	<char>	<int>	<char>	<int>	<char>
1:	41	männlich	1	Bonn	60	selten
2:	34	weiblich	13	Düsseldorf	25	oft
3:	38	weiblich	25	Dinslaken	50	oft
4:	38	männlich	5	Donezk	57	manchmal
5:	31	weiblich	16	Charkov Ukraine	135	oft
6:	36	weiblich	1	Rybnik	90	manchmal
7:	45	männlich	1	Gelsenkirchen	85	oft

Da alle Ausdrücke in `i` im Kontext der `data.table` ausgewertet werden, müssen wir den (eventuell sehr langen) Namen des Objektes nicht erneut eingeben. Dies ist vor allem bei längeren Ausdrücken sehr bequem.

```
# erzeuge langen Objektnamen
langer.Objekt.name <- dt
```

Der klassische R-Aufruf

```
# klassischer R-Befehl
langer.Objekt.name[langer.Objekt.name$alter > 25 &
                    langer.Objekt.name$geschlecht=="männlich" |
                    langer.Objekt.name$stifte > 30]
```

	alter	geschlecht	stifte	geburtsort	fahrzeit	podcast
	<int>	<char>	<int>	<char>	<int>	<char>
1:	41	männlich	1	Bonn	60	selten
2:	26	männlich	5	Düsseldorf	40	nie
3:	38	männlich	5	Donezk	57	manchmal
4:	20	weiblich	32	Wesel	89	nie
5:	45	männlich	1	Gelsenkirchen	85	oft

verkürzt sich auf

```
langer.Objekt.name[alter > 25 & geschlecht=="männlich" | stifte > 30]
```

	alter	geschlecht	stifte	geburtsort	fahrzeit	podcast
	<int>	<char>	<int>	<char>	<int>	<char>
1:	41	männlich	1	Bonn	60	selten
2:	26	männlich	5	Düsseldorf	40	nie
3:	38	männlich	5	Donezk	57	manchmal
4:	20	weiblich	32	Wesel	89	nie
5:	45	männlich	1	Gelsenkirchen	85	oft

## 2.7. Fälle sortieren mit i

Dem Parameter `i` können auch Funktionen übergeben werden. So lassen sich die Daten beispielsweise über die `order()`-Funktion sortieren.

```
# nehme anderen (kürzeren) Datensatz zur Demonstration
dt2[order(Alter)]
```

	Geschlecht	Alter	Gewicht	Groesse
	<char>	<int>	<int>	<int>
1:	w	18	55	174
2:	w	19	74	178
3:	m	21	84	185
4:	m	22	78	184
5:	w	25	74	183
6:	w	26	56	163
7:	w	27	65	169
8:	m	28	80	170
9:	m	29	101	190
10:	m	31	88	189

```
# absteigend
dt2[order(Gewicht, decreasing = TRUE)]
```

	Geschlecht	Alter	Gewicht	Groesse
	<char>	<int>	<int>	<int>
1:	m	29	101	190
2:	m	31	88	189
3:	m	21	84	185
4:	m	28	80	170
5:	m	22	78	184
6:	w	25	74	183
7:	w	19	74	178
8:	w	27	65	169
9:	w	26	56	163
10:	w	18	55	174

## 2.8. Daten verarbeiten mit j

Nachdem der Datensatz mittels `i` eventuell vorsortiert und -gefiltert wurde, erfolgen die eigentlichen Operationen über den Parameter `j`. So können wir den Mittelwert des Alters der Probanden wie folgt bestimmen:

```
# Mittelwert des Alters
dt[, mean(alter)]
```

```
[1] 25.2973
```

```
# Mittelwert des Alters der Männer
dt[geschlecht == "männlich", mean(alter)]
```

```
[1] 29
```

Innerhalb von `j` kann jede Funktion verwendet werden. So könnten wir überprüfen, ob die Variablen `fahrzeit` und `alter` miteinander korrelieren (ja, das ist quatsch).

```
# korrelieren alter und fahrzeit?
dt[, cor(alter, fahrzeit)]
```

```
[1] 0.1504465
```

Es können auch mehrere Funktionen angewendet werden. Hierfür müssen diese per `list()` an den Parameter `j` übergeben werden. Auf diese Weise könnten wir Median, Mittelwert und Standardabweichung des Alters der Probanden bestimmen.

```
# mehrere Funktionen per list()
dt[, list(Median = median(alter),
          Mittelw = mean(alter),
          Stdabw = sd(alter))]
```

```

Median Mittelw Stdabw
<int> <num> <num>
1: 22 25.2973 6.765373

```

Da der Parameter `j` immer eine Liste erwartet, kann die Funktion `list()` mit einem Punkt abgekürzt werden.

```

# geht auch mit "."
dt[, .(Median = median(alter),
      Mittelw = mean(alter),
      Stdabw = sd(alter),
      InterquA = IQR(alter))]

```

```

Median Mittelw Stdabw InterquA
<int> <num> <num> <num>
1: 22 25.2973 6.765373 6

```

## 2.9. Daten bearbeiten mit `j`

Über den Parameter `j` können die Daten auch manipuliert werden, ähnlich wie bei der `mutate()`-Funktion des `Tidyverse`. Eine neue Variable kann über die Zeichenkette `:=` definiert werden (dem so genannten *Walrus Operator* (Walross-Operator), der so heisst, weil die Zeichenfolge `:=` an die Stoßzähne eines Walrosses erinnert. Das Logo des `data.table`-Pakets zeigt eine Robbe, was zur humorvollen Verbindung beigetragen hat).

Mit folgendem Aufruf erzeugen wir eine neue Variable `FahrzeitH`, welche die `fahrzeit` in Stunden beinhalten soll.

```

# FahrzeitH in Stunden
dt[, FahrzeitH := fahrzeit/60]

# anzeigen
str(dt)

```

```

Classes 'data.table' and 'data.frame': 37 obs. of 7 variables:
 $ alter      : int 20 28 41 34 26 38 28 21 27 26 ...
 $ geschlecht: chr "weiblich" "weiblich" "männlich" "weiblich" ...
 $ stifte     : int 12 7 1 13 18 25 29 1 2 5 ...
 $ geburtsort: chr "Düren" "Neuss" "Bonn" "Düsseldorf" ...
 $ fahrzeit   : int 1 45 60 25 15 50 40 60 60 40 ...
 $ podcast    : chr "selten" "selten" "selten" "oft" ...
 $ FahrzeitH  : num 0.0167 0.75 1 0.4167 0.25 ...
- attr(*, ".internal.selfref")=externalptr>
- attr(*, "index")= int(0)
..- attr(*, "__geschlecht")= int [1:37] 3 8 10 11 13 31 33 34 37 1 ...

```

So können wir auch mittels der `cut()`-Funktion die Daten klassieren, zum Beispiel das Alter:

```

dt[, alterK := cut(alter, breaks=c(0,20,25,30,40,50),
                  ordered=TRUE)]

# anzeigen
str(dt)

```

```
Classes 'data.table' and 'data.frame': 37 obs. of 8 variables:
 $ alter      : int  20 28 41 34 26 38 28 21 27 26 ...
 $ geschlecht: chr   "weiblich" "weiblich" "männlich" "weiblich" ...
 $ stifte     : int  12 7 1 13 18 25 29 1 2 5 ...
 $ geburtsort: chr   "Düren" "Neuss" "Bonn" "Düsseldorf" ...
 $ fahrzeit   : int   1 45 60 25 15 50 40 60 60 40 ...
 $ podcast    : chr   "selten" "selten" "selten" "oft" ...
 $ FahrzeitH  : num   0.0167 0.75 1 0.4167 0.25 ...
 $ alterK     : Ord.factor w/ 5 levels "(0,20]"<"(20,25]"<...: 1 3 5 4 3 4 3 2 3 3 ...
- attr(*, ".internal.selfref")=<externalptr>
- attr(*, "index")= int(0)
..- attr(*, "__geschlecht")= int [1:37] 3 8 10 11 13 31 33 34 37 1 ...
```

Pro Aufruf kann der Walross-Operator nur einmal verwendet werden. Sollen mehrere Variablen verändert oder hinzugefügt werden, steht die `let()`-Funktion bereit. Innerhalb von `let()` werden wie gewohnt *einfache* Gleichheitszeichen verwendet.

```
# mehrere Manipulationen per let()
dt[, let(geschlecht = factor(geschlecht),
        geburtsort = factor(geburtsort),
        podcast = factor(podcast, ordered=TRUE,
                        levels=c("nie", "selten", "manchmal",
                                "oft", "immer")))]

# anzeigen
str(dt)
```

```
Classes 'data.table' and 'data.frame': 37 obs. of 8 variables:
 $ alter      : int  20 28 41 34 26 38 28 21 27 26 ...
 $ geschlecht: Factor w/ 2 levels "männlich","weiblich": 2 2 1 2 2 2 2 1 2 1 ...
 $ stifte     : int  12 7 1 13 18 25 29 1 2 5 ...
 $ geburtsort: Factor w/ 26 levels "Bagdad","Bonn",...: 9 21 2 10 8 5 21 7 18 10 ...
 $ fahrzeit   : int   1 45 60 25 15 50 40 60 60 40 ...
 $ podcast    : Ord.factor w/ 5 levels "nie"<"selten"<...: 2 2 2 4 NA 4 4 3 1 1 ...
 $ FahrzeitH  : num   0.0167 0.75 1 0.4167 0.25 ...
 $ alterK     : Ord.factor w/ 5 levels "(0,20]"<"(20,25]"<...: 1 3 5 4 3 4 3 2 3 3 ...
- attr(*, ".internal.selfref")=<externalptr>
- attr(*, "index")= int(0)
```

Die Änderungen wurden direkt im Objekt `dt` gespeichert.

## 2.10. data.table kopieren

Eine weitere wesentliche Eigenschaft von `data.table`-Objekten besteht darin, dass man sie gesondert kopieren muss. Wir eine `data.table` auf klassischem Wege in ein neues Objekt “kopiert”, so erfolgt keine echte Kopie, sondern lediglich ein *symbolischer Link* auf das ursprüngliche Objekt.

```
# weise dt einem neuen Objekt zu
neu <- dt

str(neu)
```

```
Classes 'data.table' and 'data.frame': 37 obs. of 8 variables:
 $ alter      : int  20 28 41 34 26 38 28 21 27 26 ...
 $ geschlecht: Factor w/ 2 levels "männlich","weiblich": 2 2 1 2 2 2 2 1 2 1 ...
 $ stifte     : int  12 7 1 13 18 25 29 1 2 5 ...
 $ geburtsort: Factor w/ 26 levels "Bagdad","Bonn",...: 9 21 2 10 8 5 21 7 18 10 ...
 $ fahrzeit   : int   1 45 60 25 15 50 40 60 60 40 ...
 $ podcast    : Ord.factor w/ 5 levels "nie"<"selten"<...: 2 2 2 4 NA 4 4 3 1 1 ...
 $ FahrzeitH  : num   0.0167 0.75 1 0.4167 0.25 ...
 $ alterK     : Ord.factor w/ 5 levels "(0,20]"<"(20,25]"<...: 1 3 5 4 3 4 3 2 3 3 ...
 - attr(*, ".internal.selfref")=<externalptr>
 - attr(*, "index")= int(0)
```

Wir haben das Objekt `dt` nur *scheinbar* in das neue Objekt `neu` kopiert. Wenn wir Änderungen am Objekt `neu` vornehmen, so sind diese auch im Objekt `dt` präsent, weil eben **nicht** kopiert, sondern nur ein *Verweis* erstellt wurde.

```
# erstelle neue Variable in "neu"
neu[, kuckuck := fahrzeit * stifte]

# die neue Variable ist auch in "dt" enthalten
str(dt)
```

```
Classes 'data.table' and 'data.frame': 37 obs. of 9 variables:
 $ alter      : int  20 28 41 34 26 38 28 21 27 26 ...
 $ geschlecht: Factor w/ 2 levels "männlich","weiblich": 2 2 1 2 2 2 2 1 2 1 ...
 $ stifte     : int  12 7 1 13 18 25 29 1 2 5 ...
 $ geburtsort: Factor w/ 26 levels "Bagdad","Bonn",...: 9 21 2 10 8 5 21 7 18 10 ...
 $ fahrzeit   : int   1 45 60 25 15 50 40 60 60 40 ...
 $ podcast    : Ord.factor w/ 5 levels "nie"<"selten"<...: 2 2 2 4 NA 4 4 3 1 1 ...
 $ FahrzeitH  : num   0.0167 0.75 1 0.4167 0.25 ...
 $ alterK     : Ord.factor w/ 5 levels "(0,20]"<"(20,25]"<...: 1 3 5 4 3 4 3 2 3 3 ...
 $ kuckuck    : int  12 315 60 325 270 1250 1160 60 120 200 ...
 - attr(*, ".internal.selfref")=<externalptr>
 - attr(*, "index")= int(0)
```

**!** Dies ist ein häufiger fataler Anfängerfehler, der zum Datenverlust führen kann!

Um das Objekt tatsächlich zu kopieren, muss die Funktion `copy()` verwendet werden.

```
# kopieren dt2 nach neu2
neu2 <- copy(dt2)

# anzeigen
str(neu2)
```

```
Classes 'data.table' and 'data.frame': 10 obs. of 4 variables:
 $ Geschlecht: chr  "m" "w" "w" "m" ...
 $ Alter     : int  28 18 25 29 21 19 27 26 31 22
 $ Gewicht   : int  80 55 74 101 84 74 65 56 88 78
 $ Groesse   : int  170 174 183 190 185 178 169 163 189 184
 - attr(*, ".internal.selfref")=<externalptr>
```

```
# manipulieren
neu2[, Kuckuck := Groesse/Gewicht]

# dt2 ist unverändert
str(dt2)
```

```
Classes 'data.table' and 'data.frame': 10 obs. of 4 variables:
 $ Geschlecht: chr "m" "w" "w" "m" ...
 $ Alter : int 28 18 25 29 21 19 27 26 31 22
 $ Gewicht : int 80 55 74 101 84 74 65 56 88 78
 $ Groesse : int 170 174 183 190 185 178 169 163 189 184
 - attr(*, ".internal.selfref")=<externalptr>
```

## 2.11. pipen

Innerhalb von `data.table` kann auch die Pipe verwendet werden. Wird die R-Base-Pipe `|>` verwendet, kann mittels Unterstrich `_` auf den weitergeleiteten Datenstrom zugegriffen werden. Bei der Tidyverse-Pipe (eigentlich von `magrittr`) mit der Zeichenfolge `%>%` muss ein Punkt `.` verwendet werden.

Folgende Aufrufe filtern das Geschlecht und pipen den Datenstrom weiter. Anschließend wird nach Alter sortiert.

```
# Daten pipen mit R_Base
dt2[Geschlecht=="m"] |>
  _[order(Alter)]
```

	Geschlecht	Alter	Gewicht	Groesse
	<char>	<int>	<int>	<int>
1:	m	21	84	185
2:	m	22	78	184
3:	m	28	80	170
4:	m	29	101	190
5:	m	31	88	189

```
# Daten pipen mit magrittr
dt2[Geschlecht=="m"] %>%
  .[order(Alter)]
```

	Geschlecht	Alter	Gewicht	Groesse
	<char>	<int>	<int>	<int>
1:	m	21	84	185
2:	m	22	78	184
3:	m	28	80	170
4:	m	29	101	190
5:	m	31	88	189

Oder wir erstellen ein lineares Modell und pipen es an die `summary()`-Funktion weiter.



```
dt2[, lm(Gewicht ~ Groesse)] |>
  summary()
```

Call:

```
lm(formula = Gewicht ~ Groesse)
```

Residuals:

Min	1Q	Median	3Q	Max
-14.9024	-3.4756	-0.3902	1.0915	15.0732

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-146.5366	58.3503	-2.511	0.03630 *
Groesse	1.2439	0.3265	3.810	0.00516 **

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.992 on 8 degrees of freedom

Multiple R-squared: 0.6447, Adjusted R-squared: 0.6003

F-statistic: 14.51 on 1 and 8 DF, p-value: 0.005164

Wir können den Ausdruck aber auch direkt in die `summary()`-Funktion schreiben.

```
summary(dt2[, lm(Gewicht ~ Groesse)])
```

Call:

```
lm(formula = Gewicht ~ Groesse)
```

Residuals:

Min	1Q	Median	3Q	Max
-14.9024	-3.4756	-0.3902	1.0915	15.0732

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-146.5366	58.3503	-2.511	0.03630 *
Groesse	1.2439	0.3265	3.810	0.00516 **

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.992 on 8 degrees of freedom

Multiple R-squared: 0.6447, Adjusted R-squared: 0.6003

F-statistic: 14.51 on 1 and 8 DF, p-value: 0.005164

## 2.12. Ergebnisse gruppieren mit `by`

Über den Parameter `by` können die Ergebnisse gruppiert werden.

```
# gruppiert nach Geschlecht
dt[, .(Median = median(alter),
      Mittelw = mean(alter),
      Stdabw = sd(alter)),
  by = geschlecht]
```

	geschlecht	Median	Mittelw	Stdabw
	<fctr>	<num>	<num>	<num>
1:	weiblich	21.5	24.10714	5.251732
2:	männlich	25.0	29.00000	9.617692

Die Ausgabe kann gepipet und weiterverarbeitet werden. In folgendem Beispiel berechnen wir den Variationskoeffizienten ( $sd/\bar{x}$ ) aus den gruppierten Ergebnissen.

```
dt[, .(Median = median(alter),
      Mittelw = mean(alter),
      Stdabw = sd(alter)),
  by = geschlecht] |>
# berechnen
_[, VK := Stdabw / Mittelw] |>
# anzeigen
_[]
```

	geschlecht	Median	Mittelw	Stdabw	VK
	<fctr>	<num>	<num>	<num>	<num>
1:	weiblich	21.5	24.10714	5.251732	0.2178496
2:	männlich	25.0	29.00000	9.617692	0.3316446

Bitte beachten Sie, dass wir in diesem Beispiel die Anzeige der Endergebnisse mittels `|> _[]` erzwingen mussten. Dies ist notwendig, wenn per `by` gruppierte Ergebnisse weiter manipuliert werden sollen. `Data.table` speichert Änderungen durch `:=` immer direkt im Objekt, wobei keine Ausgabe der Daten erfolgt. Im vorliegenden Fall von `VK := Stdabw / Mittelw` ist diese Speicherung jedoch nicht möglich (ausgegeben wird ja eh nichts), da sich das Endergebnis nicht mehr auf das ursprüngliche Objekt `dt` bezieht. In diesem Fall ist es (sogar) möglich und üblich, das Ergebnis wie gewohnt in einem neuen Objekt zu *speichern*, ohne dass dabei ein symbolischer Link angelegt wird.

```
neu3 <- dt[, .(Median = median(alter),
              Mittelw = mean(alter),
              Stdabw = sd(alter)),
  by = geschlecht] |>
_[, VK := Stdabw / Mittelw] |>
_[]

# anzeigen
neu3
```

	geschlecht	Median	Mittelw	Stdabw	VK
	<fctr>	<num>	<num>	<num>	<num>
1:	weiblich	21.5	24.10714	5.251732	0.2178496
2:	männlich	25.0	29.00000	9.617692	0.3316446

Wir können den letzten Pipevorgang abkürzen, indem wir einfach eckige Klammern [] an unseren Aufruf anhängen.

```
neu4 <- dt[, .(Median = median(alter),
              Mittelw = mean(alter),
              Stdabw = sd(alter)),
            by = geschlecht] |>
  _[, VK := Stdabw / Mittelw][]

# anzeigen
neu4
```

	geschlecht	Median	Mittelw	Stdabw	VK
	<fctr>	<num>	<num>	<num>	<num>
1:	weiblich	21.5	24.10714	5.251732	0.2178496
2:	männlich	25.0	29.00000	9.617692	0.3316446

## 2.13. Weitere Funktionen aus dem data.table Paket

Das Paket data.table bringt zahlreiche eigene Funktionen mit, um typische Aufgabenstellungen effizienter bearbeiten zu können.

### 2.13.1. Einzigartige bestimmen mit uniqueN

Um zum Beispiel die Anzahl verschiedener Städte innerhalb der Variable geburtsort zu bestimmen, können wir auf die paketeigene Funktion uniqueN() zurückgreifen:

```
# wieviele unterschiedliche Städte sind in "geburtsort"?
dt[, uniqueN(geburtsort)]
```

```
[1] 26
```

### 2.13.2. Anzahl der Fälle mit .N

Mit der Funktion .N kann die Anzahl der Fälle ermittelt werden.

```
dt[, .(Anzahl = .N),
     by = geschlecht]
```

	geschlecht	Anzahl
	<fctr>	<int>
1:	weiblich	28
2:	männlich	9

Mit Hilfe von nrow() können so prozentuale Anteile berechnet werden.


```
dt[, .(Anzahl = .N,
       Prozent = .N/nrow(dt)*100),
     by = alterK]
```

	alterK	Anzahl	Prozent
	<ord>	<int>	<num>
1:	(0,20]	9	24.324324
2:	(25,30]	6	16.216216
3:	(40,50]	2	5.405405
4:	(30,40]	5	13.513514
5:	(20,25]	15	40.540541

Die Ergebnisse können an `ggplot()` weitergereicht werden.

```
# ggplot
library(ggplot2)

dt[, .(Anzahl = .N,
       Prozent = .N/nrow(dt)*100),
     by = alterK] |>
ggplot(aes(x=alterK, y=Prozent)) +
geom_col(color="black", fill="orchid")
```



### 2.13.3. Lange Tabelle erzeugen mit `melt()`

Mit der Funktion `melt()` können breite Tabellen in lange (tidy) umgewandelt werden, ähnlich wie mit `dplyr::pivot_longer()`. Zur Demonstration verwenden wir die Pflgetabelle von Isfort (2018)

```
# lade Testdaten
load("https://www.produnis.de/tabletrainer/data/Pflegeberufe.RData")
```

	1999	2001	2003	2005	2007	2009	2011	2013
Krankenpflegeassistenz	16624	19061	19478	21537	27731	36481	46517	54371
Altenpflegehilfe	55770	52710	49727	45776	48326	47903	47978	48363
Kinderkrankenpflege	47779	48203	48822	48519	49080	49307	48291	48937

Krankenpflege	430983	436767	444783	449355	457322	465446	468192	472580
Altenpflege	109161	124879	141965	158817	178902	194195	208304	227154
	2015							
Krankenpflegeassistentz	64127							
Altenpflegehilfe	49507							
Kinderkrankenpflege	48913							
Krankenpflege	476416							
Altenpflege	246412							

Die Tabelle ist nicht *tidy* und liegt im breiten Format vor. Ausserdem ist sie von der Klasse `matrix`.

```
# wandeln um in data.table
pf <- as.data.table(Pflegeberufe, keep.rownames = "Berufsgruppe")

# anzeigen
pf
```

	Berufsgruppe	1999	2001	2003	2005	2007	2009	2011
	<char>	<num>	<num>	<num>	<num>	<num>	<num>	<num>
1:	Krankenpflegeassistentz	16624	19061	19478	21537	27731	36481	46517
2:	Altenpflegehilfe	55770	52710	49727	45776	48326	47903	47978
3:	Kinderkrankenpflege	47779	48203	48822	48519	49080	49307	48291
4:	Krankenpflege	430983	436767	444783	449355	457322	465446	468192
5:	Altenpflege	109161	124879	141965	158817	178902	194195	208304
	2013	2015						
	<num>	<num>						
1:	54371	64127						
2:	48363	49507						
3:	48937	48913						
4:	472580	476416						
5:	227154	246412						

Mittels `melt()` transformieren wir `pf` in eine lange (*tidy*) Tabelle. Dabei übergeben wir dem Parameter

- `id.vars` alle Variablen, welche "Identifikatoren" beinhalten. Damit sind alle Spalten gemeint, die keine konkreten Messwerte enthalten, sondern weitere *bezeichnende* Kennwerte. Klassischer Weise sind dies vor allem die **Zeilen**namen, in unserem Falle also `Berufsgruppe`. Es können mehrere `id.vars` mittels `c()` aneinandergereiht werden.
- `measure.vars` alle Spalten, welche die eigentlichen Messwerte enthalten, in unserem Falle 1999:2015 (alles außer `Berufsgruppe`). Wird dieser Parameter leer gelassen, nimmt `data.table` automatisch alle Spalten, die keine `id.vars` sind.
- `variable.name` den Name der neuen Spalte, in welche die Bezeichnungen der `measure.vars` überführt werden sollen, in unserem Fall `Jahr`.
- `value.name` den Name der neuen Spalte, in welche die Werte der `measure.vars` überführt werden sollen, in unserem Fall `Anzahl`.

Da wir alle Spalten außer `Berufsgruppe` *melten* wollen, kann der Parameter `measure.vars` weggelassen werden.

```
# pf mit melt() tidy machen
pf_tidy <- melt(pf, id.vars = "Berufsgruppe",
               variable.name = "Jahr",
               value.name = "Anzahl")
```

```
# anschauen
head(pf_tidy)
```

	Berufsgruppe	Jahr	Anzahl
	<char>	<fctr>	<num>
1:	Krankenpflegeassistenz	1999	16624
2:	Altenpflegehilfe	1999	55770
3:	Kinderkrankenpflege	1999	47779
4:	Krankenpflege	1999	430983
5:	Altenpflege	1999	109161
6:	Krankenpflegeassistenz	2001	19061

#### 2.13.4. Breite Tabelle erzeugen mit dcast()

Mittels `dcast()` können lange Tabellen wieder in breite Tabellen transformiert werden, so wie bei `dplyr::pivot_wider()`.

Der Aufruf folgt der Semantik:

```
dcast(Bezeichner ~ Spaltenname, value.var = "Wertename")
```

wobei

- `Bezeichner` die Spalten der `id.vars` meint.
- `Spaltenname` die Spalte mit der `variable.name` meint.
- `value.var` den Namen der Spalte meint, welche die konkreten Messwerte enthält. Diese muss in Anführungszeichen angegeben werden. Wird dieser Parameter weggelassen, versucht `data.table` die korrekte Spalte zu erraten (was einfach ist, wenn nur noch eine Spalte übrig bleibt).

```
# wandle pf_tidy mit dcast() in breite Tabelle
pf_wide <- dcast(pf_tidy, Berufsgruppe ~ Jahr,
                 value.var = "Anzahl")
```

```
# anschauen
head(pf_wide)
```

Key: <Berufsgruppe>

	Berufsgruppe	1999	2001	2003	2005	2007	2009	2011
	<char>	<num>	<num>	<num>	<num>	<num>	<num>	<num>
1:	Altenpflege	109161	124879	141965	158817	178902	194195	208304
2:	Altenpflegehilfe	55770	52710	49727	45776	48326	47903	47978
3:	Kinderkrankenpflege	47779	48203	48822	48519	49080	49307	48291
4:	Krankenpflege	430983	436767	444783	449355	457322	465446	468192
5:	Krankenpflegeassistenz	16624	19061	19478	21537	27731	36481	46517
	2013	2015						
	<num>	<num>						
1:		227154	246412					
2:		48363	49507					
3:		48937	48913					
4:		472580	476416					
5:		54371	64127					

# **Teil I.**

## **Aufgaben**

## 3. Aufgaben

Schön, dass Sie Ihre `data.table` überprüfen und festigen möchten. Bleiben Sie am Ball, Sie schaffen das!

### 3.1. Aufgabe 3.1 Größe und Gewicht

**i** Von 10 Personen wurden folgende Körpergrößen in Meter gemessen:

1,68	1,87	1,95	1,74	1,80
1,75	1,59	1,77	1,82	1,74

... sowie folgende Gewichte in Gramm:

78500	110100	97500	69200	82500
71500	81500	87200	75500	65500

- Überführen Sie die Daten in eine `data.table` mit den Variablen `Groesse` und `Gewicht`.
- Rechnen Sie das Gewicht um in Kilogramm, und speichern Sie Ihr Ergebnis in der neuen Variable `Kilogramm`.
- Lassen Sie die Daten von Proband 4, 7 und 9 ausgeben.
- Lassen Sie die Daten der Probanden ausgeben, deren Gewicht größer ist als 80kg.
- Lassen Sie die Daten der Probanden ausgeben, die größer als 1,7m sind und leichter als 85kg.
- Speichern Sie Ihr `data.table`-Objekt in die Datei `groegew.csv`. Lassen Sie sich dabei zunächst anzeigen, was in die Datei geschrieben werden wird.

**💡** Lösung siehe Abschnitt 4.1



## 3.2. Aufgabe 3.2 Datentabelle

**i** Von 6 Probanden wurde der Cholesterolspiegel in mg/dl gemessen.

Name	Geschlecht	Gewicht	Größe	Cholesterol
Anna Tomie	W	85	179	182
Bud Zillus	M	115	173	232
Dieter Mietenplage	M	79	181	191
Hella Scheinwerfer	W	60	170	200
Inge Danken	W	57	158	148
Jason Zufall	M	96	174	249


- a) Übertragen Sie die Daten in eine `data.table` mit dem Namen `chol`.  
 b) Erstellen Sie eine neue Variable `Alter`, die zwischen `Name` und `Geschlecht` liegt und folgende Daten beinhaltet:

Name	Alter
Anna Tomie	18
Bud Zillus	32
Dieter Mietenplage	24
Hella Scheinwerfer	35
Inge Danken	46
Jason Zufall	68

- c) Fügen Sie einen weiteren Fall mit folgenden Daten dem Datenframe hinzu

Name	Alter	Geschlecht	Gewicht	Größe	Cholesterol
Mitch Mackes	44	M	92	178	220

- d) Erzeugen Sie eine neue Variable `BMI` ( $BMI = \frac{kg}{m^2}$ ).  
 e) Fügen Sie die Variable `Adipositas` hinzu, in welcher Sie die BMI-Werte wie folgt klassieren:
- weniger als 18,5 → Untergewicht
  - zwischen 18,5 und 24.5 → Normalgewicht
  - zwischen 24,5 und 30 → Übergewicht
  - größer als 30 → Adipositas
- f) Filtern Sie Ihren Datensatz, so dass Sie einen neuen Datensatz `male` erhalten, welcher nur die Daten der Männer beinhaltet.  
 g) Speichern Sie die Objekte `chol` und `male` als Textdatei auf Ihre Festplatte. Lassen Sie sich dabei jeweils zuvor anzeigen, welcher Inhalt in die Textdatei geschrieben werden wird.

 Lösung siehe Abschnitt 4.2

### 3.3. Aufgabe 3.3 Big Five

**i** `{data.table}` ist vor allem bei großen Datensätzen beliebt, da es schneller ist als *herkömmliches* R. Die Datei `big_five_scores.csv` enthält Daten von 307.313 Probanden aus 236 Ländern zu den *Big Five* der Persönlichkeitspsychologie, siehe [https://de.wikipedia.org/wiki/Big\\_Five\\_\(Psychologie\)](https://de.wikipedia.org/wiki/Big_Five_(Psychologie)). Die Datei liegt als ZIP-Paket unter [https://www.produnis.de/tabletrainer/data/big\\_five.zip](https://www.produnis.de/tabletrainer/data/big_five.zip). Laden Sie die ZIP Datei herunter, und entpacken Sie `big_five_scores.csv` in Ihren Projektordner (bzw. dort in den `data`-Ordner).

**!** Der Datensatz beinhaltet folgende Variablen

- `case_id`: Eindeutige ID der Person, zu der die Ergebnisse gehören
- `country`: Herkunftsland der Person
- `age`: Alter der Person
- `sex`: biologisches Geschlecht der Person. 1 = männlich, 2 = weiblich

Die restlichen Spalten sind die Punktzahlen der Person von 0 bis 1 für jede ihrer fünf großen Persönlichkeitsmerkmale:

- `Agreeableness` (Verträglichkeit)
- `Extraversion` (Extraversion)
- `Openness` (Offenheit)
- `Conscientiousness` (Gewissenhaftigkeit)
- `Neuroticism` (Neurotizismus).


- a) Lesen Sie den Datensatz `big_five_scores.csv` als `data.table` in Ihre R-Session und machen Sie sich mit dem Datensatz vertraut.
- b) Ändern Sie die Geschlechtskodierung, so dass `männlich` und `weiblich` verwendet werden.
- c) Passen Sie das Skalenniveau der Variablen an.

**💡** Lösung siehe Abschnitt 4.3

### 3.4. Aufgabe 3.4 Rolling Stone Magazine

**i** Die Datei `rolling_stone.csv` enthält die *500 Greatest Albums of All Time* Listen des Rolling Stone Magazines aus den Jahren 2003, 2012 und 2020. Der Datensatz stammt aus dem *Tidy Tuesday* Projekt (2022) vom 07.05.2024 und kann auch unter [https://www.produnis.de/tabletrainer/data/rolling\\_stone.csv](https://www.produnis.de/tabletrainer/data/rolling_stone.csv) heruntergeladen werden.

- a) Laden Sie die Datei `rolling_stone.csv` als `data.table` in Ihre R-Session und machen Sie sich mit dem Datensatz vertraut.
- b) Passen Sie das Skalenniveau der Variablen an.
- c) Welche sind die Nummer 1 Alben der Jahre 2003, 2012 und 2020?
- d) Ist Ihre Lieblingsband in der Liste?
- e) Welche weiblichen Bands haben mehr als 3 Mitglieder?
- f) Welche Band hat die meisten Alben im Datensatz?
- g) Prüfen Sie per Korrelationsverfahren, ob die Beliebtheit bei Spotify (`spotify_popularity`) mit der Liste von 2020 übereinstimmt.
- h) Welchen durchschnittlichen Rang erzielen Alben des Genres "Electronic" in den Jahren 2003, 2012 und 2020?
- i) Berechnen Sie das arithmetische Mittel und den Median des Albenrankings für jedes Genre im Jahr 2020. Wieviele Alben sind pro Genre enthalten? Sortieren Sie die Ausgabe einmal absteigend nach dem Median, und einmal aufsteigend nach `genre`.
- j) Wieviele Bands sind in jeder der 3 Listen vertreten, wieviele Alben sind in jeder der 3 Listen vertreten, welche Alben ist in jeder der 3 Listen auf dem selben Platz, welche haben sich kontinuierlich verbessert, welche kontinuierlich verschlechtert?
- k) Der Datensatz liegt als `wide.table` vor, da das Ranking für 2003, 2012 und 2020 als Variablen nebeneinander stehen. Wandeln Sie den Datensatz in eine `long.table` (Tidy Data) um, so dass die Rankingangaben in den Variablen `Rang` und `Rangjahr` angegeben sind.

 Lösung siehe Abschnitt 4.4

## **Teil II.**

# **Lösungswege**

## 4. Lösungswege

⚠ Gerade als Anfänger:in sollten Sie zumindest *versuchen*, die Aufgaben selbstständig zu lösen, bevor Sie sich die Lösungswege anschauen. Kopf hoch, Sie schaffen das!

### 4.1. Lösung zur Aufgabe 3.1 Größe und Gewicht

💡 a) Überführen Sie die Daten in eine `data.table` mit den Variablen `Groesse` und `Gewicht`.

```
# Paket aktivieren
library(data.table)

# Überführe in eine data.table
dt <- data.table(Groesse = c(1.68, 1.87, 1.95, 1.74, 1.80, 1.75, 1.59,
                             1.77, 1.82, 1.74),
                 Gewicht = c(78500, 110100, 97500, 69200, 82500, 71500,
                             81500, 87200, 75500, 65500)
)

# anzeigen
dt
```

	Groesse	Gewicht
	<num>	<num>
1:	1.68	78500
2:	1.87	110100
3:	1.95	97500
4:	1.74	69200
5:	1.80	82500
6:	1.75	71500
7:	1.59	81500
8:	1.77	87200
9:	1.82	75500
10:	1.74	65500

💡 b) Rechnen Sie das Gewicht um in Kilogramm, und speichern Sie Ihr Ergebnis in der neuen Variable Kilogramm

```
# Umrechnen in Kilogramm
dt[, Kilogramm := Gewicht / 1000]

# anzeigen
dt
```

	Groesse	Gewicht	Kilogramm
	<num>	<num>	<num>
1:	1.68	78500	78.5
2:	1.87	110100	110.1
3:	1.95	97500	97.5
4:	1.74	69200	69.2
5:	1.80	82500	82.5
6:	1.75	71500	71.5
7:	1.59	81500	81.5
8:	1.77	87200	87.2
9:	1.82	75500	75.5
10:	1.74	65500	65.5

💡 c) Lassen Sie die Daten von Proband 4, 7 und 9 ausgeben

```
# Ausgabe der Daten von Proband 4, 7 und 9
dt[c(4, 7, 9)]
```

	Groesse	Gewicht	Kilogramm
	<num>	<num>	<num>
1:	1.74	69200	69.2
2:	1.59	81500	81.5
3:	1.82	75500	75.5

💡 d) Lassen Sie die Daten der Probanden ausgeben, deren Gewicht größer ist als 80kg

```
dt[Kilogramm > 80]
```

	Groesse	Gewicht	Kilogramm
	<num>	<num>	<num>
1:	1.87	110100	110.1
2:	1.95	97500	97.5
3:	1.80	82500	82.5
4:	1.59	81500	81.5
5:	1.77	87200	87.2

💡 e) Lassen Sie die Daten der Probanden ausgeben, die größer als 1,7m sind und leichter als 85kg

```
dt[Groesse > 1.7 & Kilogramm < 85]
```

	Groesse	Gewicht	Kilogramm
	<num>	<num>	<num>
1:	1.74	69200	69.2
2:	1.80	82500	82.5
3:	1.75	71500	71.5
4:	1.82	75500	75.5
5:	1.74	65500	65.5

💡 f) Speichern Sie Ihr data.table-Objekt in die Datei groegew.csv. Lassen Sie sich dabei zunächst anzeigen, was in die Datei geschrieben werden wird.

```
# zeige, was in die Datei gespeichert würde
fwrite(dt)
```

```
Groesse,Gewicht,Kilogramm
1.68,78500,78.5
1.87,110100,110.1
1.95,97500,97.5
1.74,69200,69.2
1.8,82500,82.5
1.75,71500,71.5
1.59,81500,81.5
1.77,87200,87.2
1.82,75500,75.5
1.74,65500,65.5
```

```
# speichere in Datei groegew.csv
fwrite(dt, "groegew.csv")
```

## 4.2. Lösung zur Aufgabe 3.2 Datentabelle

💡 a) Übertragen Sie die Daten in eine `data.table` mit dem Namen `chol`.

```
# übertrage die Daten
chol <- data.table(Name = c("Anna Tomie", "Bud Zillus", "Dieter Mietenplage",
                           "Hella Scheinwerfer", "Inge Danken", "Jason Zufall"),
                  Geschlecht = c("W", "M", "M", "W", "W", "M"),
                  Gewicht = c(85, 115, 79, 60, 57, 96),
                  Größe = c(179, 173, 181, 170, 158, 174),
                  Cholesterol = c(182, 232, 191, 200, 148, 249)
)
# anzeigen
chol
```

	Name	Geschlecht	Gewicht	Größe	Cholesterol
	<char>	<char>	<num>	<num>	<num>
1:	Anna Tomie	W	85	179	182
2:	Bud Zillus	M	115	173	232
3:	Dieter Mietenplage	M	79	181	191
4:	Hella Scheinwerfer	W	60	170	200
5:	Inge Danken	W	57	158	148
6:	Jason Zufall	M	96	174	249

💡 b) Erstellen Sie eine neue Variable `Alter`, die zwischen `Name` und `Geschlecht` liegt

```
# Alter der Probanden
alter <- c(18, 32, 24, 35, 46, 68)

# Neue Spalte 'Alter'
chol[, Alter := alter]

# Spalte 'Alter' zwischen `Name` und `Geschlecht`
setcolorder(chol, c("Name", "Alter", "Geschlecht", "Gewicht",
                  "Größe", "Cholesterol"))

# Ausgabe der data.table
chol
```

	Name	Alter	Geschlecht	Gewicht	Größe	Cholesterol
	<char>	<num>	<char>	<num>	<num>	<num>
1:	Anna Tomie	18	W	85	179	182
2:	Bud Zillus	32	M	115	173	232
3:	Dieter Mietenplage	24	M	79	181	191
4:	Hella Scheinwerfer	35	W	60	170	200
5:	Inge Danken	46	W	57	158	148
6:	Jason Zufall	68	M	96	174	249



💡 c) Fügen Sie einen weiteren Fall mit folgenden Daten dem Datenframe hinzu

```
# Neuer Fall
neu <- data.table(Name = "Mitch Mackes",
                  Alter = 44,
                  Geschlecht = "M",
                  Gewicht = 92,
                  Größe = 178,
                  Cholesterol = 220
)

# mit rbind zusammenbringen
chol <- rbind(chol, neu)

# anzeigen
chol
```

	Name	Alter	Geschlecht	Gewicht	Größe	Cholesterol
	<char>	<num>	<char>	<num>	<num>	<num>
1:	Anna Tomie	18	W	85	179	182
2:	Bud Zillus	32	M	115	173	232
3:	Dieter Mietenplage	24	M	79	181	191
4:	Hella Scheinwerfer	35	W	60	170	200
5:	Inge Danken	46	W	57	158	148
6:	Jason Zufall	68	M	96	174	249
7:	Mitch Mackes	44	M	92	178	220

💡 d) Erzeugen Sie eine neue Variable BMI.

```
# BMI berechnen
chol[, BMI := Gewicht / (Größe / 100)^2]

# anzeigen
chol
```

	Name	Alter	Geschlecht	Gewicht	Größe	Cholesterol	BMI
	<char>	<num>	<char>	<num>	<num>	<num>	<num>
1:	Anna Tomie	18	W	85	179	182	26.52851
2:	Bud Zillus	32	M	115	173	232	38.42427
3:	Dieter Mietenplage	24	M	79	181	191	24.11404
4:	Hella Scheinwerfer	35	W	60	170	200	20.76125
5:	Inge Danken	46	W	57	158	148	22.83288
6:	Jason Zufall	68	M	96	174	249	31.70828
7:	Mitch Mackes	44	M	92	178	220	29.03674

💡 e) Fügen Sie die Variable Adipositas hinzu, in welcher Sie die BMI-Werte wie folgt klassieren

Hierzu können wir entweder die `fifelse()`-Funktion nutzen...

```
# Klassifizieren mit fifelse
chol[, Adipositas := fifelse(BMI < 18.5, "Untergewicht",
                             fifelse(BMI >= 18.5 & BMI < 24.5, "Normalgewicht",
                             fifelse(BMI >= 24.5 & BMI <= 30, "Übergewicht", "Adipositas")))]

# anzeigen
chol
```

	Name	Alter	Geschlecht	Gewicht	Größe	Cholesterol	BMI
	<char>	<num>	<char>	<num>	<num>	<num>	<num>
1:	Anna Tomie	18	W	85	179	182	26.52851
2:	Bud Zillus	32	M	115	173	232	38.42427
3:	Dieter Mietenplage	24	M	79	181	191	24.11404
4:	Hella Scheinwerfer	35	W	60	170	200	20.76125
5:	Inge Danken	46	W	57	158	148	22.83288
6:	Jason Zufall	68	M	96	174	249	31.70828
7:	Mitch Mackes	44	M	92	178	220	29.03674

	Adipositas
	<char>
1:	Übergewicht
2:	Adipositas
3:	Normalgewicht
4:	Normalgewicht
5:	Normalgewicht
6:	Adipositas
7:	Übergewicht

...oder mittels `cut()`.

```
# Klassifizieren mit cut()
chol[, Adipositas := cut(BMI,
                          breaks = c(-Inf, 18.5, 24.5, 30, Inf),
                          labels = c("Untergewicht", "Normalgewicht",
                          "Übergewicht", "Adipositas"))]

# anzeigen
chol
```

	Name	Alter	Geschlecht	Gewicht	Größe	Cholesterol	BMI
	<char>	<num>	<char>	<num>	<num>	<num>	<num>
1:	Anna Tomie	18	W	85	179	182	26.52851
2:	Bud Zillus	32	M	115	173	232	38.42427
3:	Dieter Mietenplage	24	M	79	181	191	24.11404
4:	Hella Scheinwerfer	35	W	60	170	200	20.76125
5:	Inge Danken	46	W	57	158	148	22.83288
6:	Jason Zufall	68	M	96	174	249	31.70828
7:	Mitch Mackes	44	M	92	178	220	29.03674

	Adipositas
	<fctr>

```

1: Übergewicht
2: Adipositas
3: Normalgewicht
4: Normalgewicht
5: Normalgewicht
6: Adipositas
7: Übergewicht

```

💡 f) Filtern Sie Ihren Datensatz, so dass Sie einen neuen Datensatz `male` erhalten, welcher nur die Daten der Männer beinhaltet.

```
male <- chol[Geschlecht == "M"]
```

```
# anzeigen
male
```

	Name	Alter	Geschlecht	Gewicht	Größe	Cholesterol	BMI
	<char>	<num>	<char>	<num>	<num>	<num>	<num>
1:	Bud Zillus	32	M	115	173	232	38.42427
2:	Dieter Mietenplage	24	M	79	181	191	24.11404
3:	Jason Zufall	68	M	96	174	249	31.70828
4:	Mitch Mackes	44	M	92	178	220	29.03674

	Adipositas
	<fctr>
1:	Adipositas
2:	Normalgewicht
3:	Adipositas
4:	Übergewicht

💡 g) Speichern Sie die Objekte `chol` und `male` als Textdatei auf Ihre Festplatte. Lassen Sie sich dabei jeweils zuvor anzeigen, welcher Inhalt in die Textdatei geschrieben werden wird.

```
# zeige, was in chol.txt gespeichert würde
fwrite(chol)
```

```

Name,Alter,Geschlecht,Gewicht,Größe,Cholesterol,BMI,Adipositas
Anna Tomie,18,W,85,179,182,26.528510346119,Übergewicht
Bud Zillus,32,M,115,173,232,38.4242707741655,Adipositas
Dieter Mietenplage,24,M,79,181,191,24.1140380330271,Normalgewicht
Hella Scheinwerfer,35,W,60,170,200,20.7612456747405,Normalgewicht
Inge Danken,46,W,57,158,148,22.8328793462586,Normalgewicht
Jason Zufall,68,M,96,174,249,31.7082837891399,Adipositas
Mitch Mackes,44,M,92,178,220,29.0367377856331,Übergewicht

```

```
# zeige, was in male.txt gespeichert würde
fwrite(male)
```

```
Name,Alter,Geschlecht,Gewicht,Größe,Cholesterol,BMI,Adipositas
```

```
Bud Zillus,32,M,115,173,232,38.4242707741655,Adipositas
Dieter Mietenplage,24,M,79,181,191,24.1140380330271,Normalgewicht
Jason Zufall,68,M,96,174,249,31.7082837891399,Adipositas
Mitch Mackes,44,M,92,178,220,29.0367377856331,Übergewicht
```

```
# speichere in Datei chol.txt
fwrite(chol, "chol.txt")

# speichere in Datei male.txt
fwrite(male, "male.txt")
```

### 4.3. Lösung zur Aufgabe 3.3 Big Five

💡 a) Lesen Sie den Datensatz `big_five_scores.csv` als `data.table` in Ihre R-Session.

Zunächst laden wir die Datei von [https://www.produnis.de/tabletrainer/big\\_five.zip](https://www.produnis.de/tabletrainer/big_five.zip) herunter und legen sie im `data`-Ordner (siehe Abschnitt 1.1) ab.

Wenn Sie dies bereits getan haben und die Datei `big_five_scores.csv` bereits entpackt ist, lautet der Befehl zum Einlesen der Daten:

```
# lese Daten ein
big5 <- fread("data/big_five_scores.csv")
```

Wir können die Datei aber auch direkt in R herunterladen und entpacken.

```
# File herunterladen und im "data" Ordner speichern
download.file("https://www.produnis.de/tabletrainer/data/big_five.zip",
              destfile = "data/testbig_five.zip")

# entpacken in temporäres Verzeichnis
unzip("data/big_five.zip",
      files = "big_five_scores.csv",
      exdir = tempdir())

# speichere Pfad auf temporäre Datei
pfad <- file.path(tempdir(), "big_five_scores.csv")
```

Der Befehl zum Einlesen aus der temporären Datei lautet

```
fread(pfad)
```

Falls Sie das unzip Programm auf Ihrem PC installiert haben, können Sie direkt auf das ZIP-Paket zugreifen

```
fread(cmd = 'unzip -p data/big_five.zip big_five_scores.csv')
```

Wenn das ZIP-Paket nur eine Datei enthält, muss dessen Dateiname nicht extra angegeben werden.


```
fread(cmd = 'unzip -p data/big_five.zip')
```

Mit dem Datensatz vertraut machen:

```
str(big5)
```

Classes 'data.table' and 'data.frame': 307313 obs. of 9 variables:

```
$ case_id      : int  1 3 4 5 6 7 8 9 10 11 ...
$ country      : chr   "South Afri" "UK" "USA" "UK" ...
$ age          : int  24 24 36 19 17 17 28 28 18 17 ...
$ sex          : int  1 2 2 1 1 1 2 2 1 1 ...
$ agreeable_score : num  0.753 0.733 0.88 0.69 0.6 ...
$ extraversion_score : num  0.497 0.68 0.77 0.617 0.713 ...
$ openness_score  : num  0.803 0.787 0.86 0.717 0.647 ...
$ conscientiousness_score: num  0.887 0.747 0.897 0.637 0.633 ...
$ neuroticism_score : num  0.427 0.59 0.297 0.563 0.513 ...
- attr(*, ".internal.selfref")=<externalptr>
```

 b) Ändern Sie die Geschlechtskodierung, so dass männlich und weiblich verwendet werden.

```
# Ändere die Geschlechtskodierung
big5[, sex := fifelse(sex == 1, "männlich", "weiblich")]

str(big5)
```

Classes 'data.table' and 'data.frame': 307313 obs. of 9 variables:

```
$ case_id      : int  1 3 4 5 6 7 8 9 10 11 ...
$ country      : chr   "South Afri" "UK" "USA" "UK" ...
$ age          : int  24 24 36 19 17 17 28 28 18 17 ...
$ sex          : chr   "männlich" "weiblich" "weiblich" "männlich" ...
$ agreeable_score : num  0.753 0.733 0.88 0.69 0.6 ...
$ extraversion_score : num  0.497 0.68 0.77 0.617 0.713 ...
$ openness_score  : num  0.803 0.787 0.86 0.717 0.647 ...
$ conscientiousness_score: num  0.887 0.747 0.897 0.637 0.633 ...
$ neuroticism_score : num  0.427 0.59 0.297 0.563 0.513 ...
- attr(*, ".internal.selfref")=<externalptr>
```

💡 c) Passen Sie das Skalenniveau der Variablen an.

```
# case_id und country sind nominale Variablen
big5[, let(case_id = factor(case_id),
           country = factor(country),
           sex      = factor(sex)
        )]
```

```
str(big5)
```

Classes 'data.table' and 'data.frame': 307313 obs. of 9 variables:

```
$ case_id      : Factor w/ 307313 levels "1","3","4","5",...: 1 2 3 4 5 6 7 8 9 10 ...
$ country      : Factor w/ 236 levels "", "Afghanista",...: 190 216 220 216 216 220 22
$ age          : int   24 24 36 19 17 17 28 28 18 17 ...
$ sex          : Factor w/ 2 levels "männlich", "weiblich": 1 2 2 1 1 1 2 2 1 1 ...
$ agreeable_score : num  0.753 0.733 0.88 0.69 0.6 ...
$ extraversion_score : num  0.497 0.68 0.77 0.617 0.713 ...
$ openness_score  : num  0.803 0.787 0.86 0.717 0.647 ...
$ conscientiousness_score : num  0.887 0.747 0.897 0.637 0.633 ...
$ neuroticism_score : num  0.427 0.59 0.297 0.563 0.513 ...
- attr(*, ".internal.selfref")=<externalptr>
```

## 4.4. Lösung zur Aufgabe 3.4 Rolling Stone Magazine

💡 a) Laden Sie die Datei `rolling_stone.csv` als `data.table` in Ihre R-Session und machen Sie sich mit dem Datensatz vertraut.

```
# falls schon gedownloadet
rs <- fread("data/rolling_stone.csv")
```

```
# per URL einlesen
rs <- fread("https://www.produnis.de/tabletrainer/data/rolling_stone.csv")
```

```
# anschauen
str(rs)
```

Classes 'data.table' and 'data.frame': 691 obs. of 21 variables:

```
$ sort_name      : chr  "Sinatra, Frank" "Diddley, Bo" "Presley, Elvis" "Sinatra, Fra
$ clean_name     : chr  "Frank Sinatra" "Bo Diddley" "Elvis Presley" "Frank Sinatra"
$ album          : chr  "In the Wee Small Hours" "Bo Diddley / Go Bo Diddley" "Elvis
$ rank_2003      : int   100 214 55 306 50 NA NA 421 NA 12 ...
$ rank_2012      : int   101 216 56 308 50 NA 451 420 NA 12 ...
$ rank_2020      : int   282 455 332 NA 227 32 33 NA 68 31 ...
$ differential   : int   -182 -241 -277 -195 -177 469 468 -80 433 -19 ...
$ release_year   : int   1955 1955 1956 1956 1957 2016 2006 1957 1985 1959 ...
$ genre          : chr  "Big Band/Jazz" "Rock n' Roll/Rhythm & Blues" "Rock n' Roll/R
$ type          : chr  "Studio" "Studio" "Studio" "Studio" ...
```

```

$ weeks_on_billboard      : int  14 NA 100 NA 5 87 173 NA 27 NA ...
$ peak_billboard_position : int  2 201 1 2 13 1 2 201 30 201 ...
$ spotify_popularity      : int  48 50 58 62 64 73 67 47 75 52 ...
$ spotify_url             : chr   "spotify:album:3GmwKB1tgPZgXeRJZSm9WX" "spotify:album:1cbtDEwxCjMhg1b490gNBR" "7GXP50hYyP
$ artist_member_count     : int  1 1 1 1 1 1 1 4 1 1 ...
$ artist_gender           : chr   "Male" "Male" "Male" "Male" ...
$ artist_birth_year_sum   : int  1915 1928 1935 1915 1932 1981 1983 7752 1958 1926 ...
$ debut_album_release_year: int  1946 1955 1956 1946 1957 2003 2003 1957 1978 1951 ...
$ ave_age_at_top_500      : num  40 27 21 41 25 35 23 19 27 33 ...
$ years_between          : int  9 0 0 10 0 13 3 0 7 8 ...
$ album_id               : chr   "3GmwKB1tgPZgXeRJZSm9WX" "1cbtDEwxCjMhg1b490gNBR" "7GXP50hYyP
- attr(*, ".internal.selfref")=<externalptr>

```

💡 b) Passen Sie das Skalenniveau der Variablen an.

Es gibt einige kategoriale Variablen im Datensatz.

```

rs[, let(sort_name = factor(sort_name),
      clean_name = factor(clean_name),
      album = factor(album),
      genre = factor(genre),
      tpye = factor(type),
      artist_gender = factor(artist_gender),
      album_id = factor(album_id),
      spotify_url = factor(spotify_url)
    )]

# anschauen
str(rs)

```

Classes 'data.table' and 'data.frame': 691 obs. of 22 variables:

```

$ sort_name      : Factor w/ 391 levels "2Pac","50 Cent",...: 315 92 268 315 189 25 37
$ clean_name     : Factor w/ 386 levels "2Pac","50 Cent",...: 114 40 100 114 185 27 15
$ album          : Factor w/ 685 levels "\"\"Love and Theft\"\"\"",...: 293 101 197 503
$ rank_2003      : int  100 214 55 306 50 NA NA 421 NA 12 ...
$ rank_2012      : int  101 216 56 308 50 NA 451 420 NA 12 ...
$ rank_2020      : int  282 455 332 NA 227 32 33 NA 68 31 ...
$ differential   : int  -182 -241 -277 -195 -177 469 468 -80 433 -19 ...
$ release_year   : int  1955 1955 1956 1956 1957 2016 2006 1957 1985 1959 ...
$ genre          : Factor w/ 17 levels "", "Afrobeat",...: 3 15 15 3 1 1 17 15 1 3 ...
$ type          : chr   "Studio" "Studio" "Studio" "Studio" ...
$ weeks_on_billboard : int  14 NA 100 NA 5 87 173 NA 27 NA ...
$ peak_billboard_position : int  2 201 1 2 13 1 2 201 30 201 ...
$ spotify_popularity : int  48 50 58 62 64 73 67 47 75 52 ...
$ spotify_url     : Factor w/ 656 levels "", "6Mj0v3BeIjmht2ymtRih3s",...: 280 105 623 3
$ artist_member_count : int  1 1 1 1 1 1 1 4 1 1 ...
$ artist_gender    : Factor w/ 4 levels "", "Female", "Male",...: 3 3 3 3 3 2 2 3 2 3 ...
$ artist_birth_year_sum : int  1915 1928 1935 1915 1932 1981 1983 7752 1958 1926 ...
$ debut_album_release_year: int  1946 1955 1956 1946 1957 2003 2003 1957 1978 1951 ...
$ ave_age_at_top_500 : num  40 27 21 41 25 35 23 19 27 33 ...

```

```
$ years_between      : int   9 0 0 10 0 13 3 0 7 8 ...
$ album_id          : Factor w/ 691 levels "01TG7V0g4F90jXv3a1yCgA",...: 278 103 621 364
$ tpye              : Factor w/ 5 levels "Compilation",...: 5 5 5 5 5 5 5 5 5 ...
- attr(*, ".internal.selfref")=<externalptr>
```

💡 c) Welche sind die Nummer 1 Alben der Jahre 2003, 2012 und 2020?

```
rs[rank_2003 == 1 | rank_2012 == 1 | rank_2020 == 1,
   .(clean_name, album, rank_2003, rank_2012, rank_2020)
]
```

	clean_name	album	rank_2003	rank_2012
	<fctr>	<fctr>	<int>	<int>
1:	The Beatles	Sgt. Pepper's Lonely Hearts Club Band	1	1
2:	Marvin Gaye	What's Going On	6	6
	rank_2020			
	<int>			
1:	24			
2:	1			

💡 d) Ist Ihre Lieblingsband in der Liste?

Angenommen, meine Lieblingsband sei *Faith No More*.

```
rs[clean_name == "Faith No More"]
```

Empty data.table (0 rows and 22 cols): sort\_name, clean\_name, album, rank\_2003, rank\_2012, rank\_2020

Die ist leider nicht enthalten. Versuchen wir es mit *Eminem*.

```
rs[clean_name == "Eminem", .(clean_name, album)]
```

	clean_name	album
	<fctr>	<fctr>
1:	Eminem	The Slim Shady LP
2:	Eminem	The Marshall Mathers LP
3:	Eminem	The Eminem Show

💡 e) Welche weiblichen Bands haben mehr als 3 Mitglieder?

```
rs[artist_gender == "Female" & artist_member_count > 3, .(sort_name, clean_name)]
```

	sort_name	clean_name
	<fctr>	<fctr>
1:	Destiny's Child	Destiny's Child



2:	Raincoats	The Raincoats
3:	Go Gos	The Go-Go's
4:	Ross, Diana & the Supremes	The Supremes

💡 f) Welche Band hat die meisten Alben im Datensatz?

```
# zähle die Bands und sortiere absteigend
# und zeige nur die ersten 5 Reihen an
rs[, .N, by = clean_name] |>
  _[order(-N)][1:5]
```

	clean_name	N
	<fctr>	<int>
1:	Bob Dylan	11
2:	The Beatles	11
3:	Rolling Stones	10
4:	Bruce Springsteen	9
5:	The Who	7

Bob Dylan und The Beatles haben jeweils 11 Alben in den Listen

💡 g) Prüfen Sie per Korrelationsverfahren, ob die Beliebtheit bei Spotify (spotify\_popularity) mit der Liste von 2020 übereinstimmt.

```
# Achtung, es sind NAs enthalten
rs[, cor(spotify_popularity, rank_2020, use="complete.obs")]
```

```
[1] -0.2215204
```

Es gibt einen geringen negativen Zusammenhang. Da beim Ranking ein *geringer* Wert für ein *gutes* Ranking steht, ist es auch nicht verwunderlich, dass der Zusammenhang negativ ist. Bei Spotify bedeutet ein *hoher* Wert ein gutes Ranking. Dennoch ist der Zusammenhang eher schwach.

💡 h) Welchen durchschnittlichen Rang erzielen Alben des Genres "Electronic" in den Jahren 2003, 2012 und 2020?

```
# Achtung, es sind NAs enthalten
rs[genre == "Electronic", .(d2003 = mean(rank_2003, na.rm=TRUE),
                                   d2012 = mean(rank_2012, na.rm=TRUE),
                                   d2020 = mean(rank_2020, na.rm=TRUE)
                               )]
```

	d2003	d2012	d2020
	<num>	<num>	<num>
1:	376.4286	362.1667	298.3636

💡 i) Berechnen Sie das arithmetische Mittel und den Median des Albenrankings für jedes Genre im Jahr 2020. Wieviele Alben sind pro Genre enthalten?

```
# Achtung, es sind NAs enthalten
rs[, .(mean = mean(rank_2020, na.rm=TRUE),
        median = as.numeric(median(rank_2020, na.rm=TRUE)),
        N = sum(!is.na(rank_2020))), by = genre]
```

	genre	mean	median	N
	<fctr>	<num>	<num>	<int>
1:	Big Band/Jazz	251.2000	268.0	10
2:	Rock n' Roll/Rhythm & Blues	243.2222	263.0	9
3:		254.6273	265.0	110
4:	Soul/Gospel/R&B	264.7846	275.0	65
5:	Hip-Hop/Rap	204.7544	192.0	57
6:	Blues/Blues Rock	267.6786	313.0	28
7:	Country/Folk/Country Rock/Folk Rock	223.3750	211.0	40
8:	Indie/Alternative Rock	259.8085	276.0	47
9:	Punk/Post-Punk/New Wave/Power Pop	253.8246	260.0	57
10:	Electronic	298.3636	241.0	11
11:	Funk/Disco	280.3158	360.0	19
12:	Latin	446.5000	471.0	6
13:	Hard Rock/Metal	215.6111	227.5	18
14:	Singer-Songwriter/Heartland Rock	231.8667	251.0	15
15:	Blues/Blues R0ck	259.0000	259.0	1
16:	Reggae	155.4000	140.0	5
17:	Afrobeat	433.5000	433.5	2

Haben Sie den Eintrag Blues/Blues R0ck bemerkt? Es ist ein Tippfehler im Datensatz enthalten.

```
# korrigiere den Tippfehler
rs[genre == "Blues/Blues R0ck", genre := "Blues/Blues Rock"]
```

Jetzt sortieren wir wie gewünscht einmal absteigend nach dem Median, und einmal aufsteigend nach genre.

```
# sortiert nach Median
rs[, .(mean = mean(rank_2020, na.rm=TRUE),
        median = as.numeric(median(rank_2020, na.rm=TRUE)),
        N = sum(!is.na(rank_2020))), by = genre] |>
  _[order(median, decreasing = TRUE)]
```

	genre	mean	median	N
	<fctr>	<num>	<num>	<int>
1:	Latin	446.5000	471.0	6
2:	Afrobeat	433.5000	433.5	2
3:	Funk/Disco	280.3158	360.0	19
4:	Blues/Blues Rock	267.3793	299.0	29
5:	Indie/Alternative Rock	259.8085	276.0	47
6:	Soul/Gospel/R&B	264.7846	275.0	65
7:	Big Band/Jazz	251.2000	268.0	10

```

8:                254.6273 265.0 110
9:      Rock n' Roll/Rhythm & Blues 243.2222 263.0 9
10:   Punk/Post-Punk/New Wave/Power Pop 253.8246 260.0 57
11:   Singer-Songwriter/Heartland Rock 231.8667 251.0 15
12:                Electronic 298.3636 241.0 11
13:                Hard Rock/Metal 215.6111 227.5 18
14: Country/Folk/Country Rock/Folk Rock 223.3750 211.0 40
15:                Hip-Hop/Rap 204.7544 192.0 57
16:                Reggae 155.4000 140.0 5

```

```

# sortiert nach Genre
rs[, .(mean = mean(rank_2020, na.rm=TRUE),
      median = as.numeric(median(rank_2020, na.rm=TRUE)),
      N = sum(!is.na(rank_2020))), by = genre] |>
  _[order(genre)]

```

	genre	mean	median	N
	<fctr>	<num>	<num>	<int>
1:		254.6273	265.0	110
2:	Afrobeat	433.5000	433.5	2
3:	Big Band/Jazz	251.2000	268.0	10
4:	Blues/Blues Rock	267.3793	299.0	29
5:	Country/Folk/Country Rock/Folk Rock	223.3750	211.0	40
6:	Electronic	298.3636	241.0	11
7:	Funk/Disco	280.3158	360.0	19
8:	Hard Rock/Metal	215.6111	227.5	18
9:	Hip-Hop/Rap	204.7544	192.0	57
10:	Indie/Alternative Rock	259.8085	276.0	47
11:	Latin	446.5000	471.0	6
12:	Punk/Post-Punk/New Wave/Power Pop	253.8246	260.0	57
13:	Reggae	155.4000	140.0	5
14:	Rock n' Roll/Rhythm & Blues	243.2222	263.0	9
15:	Singer-Songwriter/Heartland Rock	231.8667	251.0	15
16:	Soul/Gospel/R&B	264.7846	275.0	65

💡 j) Wieviele Bands sind in jeder der 3 Listen vertreten, wieviele Alben sind in jeder der 3 Listen vertreten, welche Alben ist in jeder der 3 Listen auf dem selben Platz, welche haben sich kontinuierlich verbessert, welche kontinuierlich verschlechtert?

```

# Anzahl der Bands, die in jeder der 3 Listen sind
rs[!is.na(rank_2003) & !is.na(rank_2012) & !is.na(rank_2020), uniqueN(clean_name)]

```

```
[1] 205
```

```

# Anzahl der Alben, die in jeder der 3 Listen sind
rs[!is.na(rank_2003) & !is.na(rank_2012) & !is.na(rank_2020), uniqueN(album)]

```

```
[1] 317
```

```
# Alben mit dem selben Ranking
rs[rank_2003 == rank_2012 & rank_2012 == rank_2020,
  .(clean_name, album, rank_2003, rank_2012, rank_2020)]
```

	clean_name	album	rank_2003	rank_2012	rank_2020
	<fctr>	<fctr>	<int>	<int>	<int>
1:	The Beach Boys	Pet Sounds	2	2	2

```
# Alben, die sich kontinuierlich verbessert haben
# (verbessert heisst, dass das Ranking kleiner wird)
rs[rank_2003 > rank_2012 & rank_2012 > rank_2020,
  .(clean_name, album, rank_2003, rank_2012, rank_2020)] |>
  _[order(clean_name)] |>
# zeige nur die ersten 10, um hier Platz zu sparen
head(10)
```

	clean_name	album	rank_2003
	<fctr>	<fctr>	<int>
1:	A Tribe Called Quest	The Low End Theory	154
2:	Big Star	Third/Sister Lovers	456
3:	Brian Eno	Here Come the Warm Jets	436
4:	Brian Eno	Another Green World	433
5:	Bruce Springsteen	Darkness on the Edge of Town	151
6:	Coldplay	A Rush of Blood to the Head	473
7:	Creedence Clearwater Revival	Willy and the Poor Boys	392
8:	Cyndi Lauper	She's So Unusual	494
9:	D'Angelo	Voodoo	488
10:	DEVO Q: Are We Not Men? A: We Are Devo!		447

	rank_2012	rank_2020
	<int>	<int>
1:	153	43
2:	449	285
3:	432	308
4:	429	338
5:	150	91
6:	466	324
7:	309	193
8:	487	184
9:	481	28
10:	442	252

```
# Alben, die sich kontinuierlich verschlechtert haben
# (verschlechtert heisst, dass das Ranking größer wird)
rs[rank_2003 < rank_2012 & rank_2012 < rank_2020,
  .(clean_name, album, rank_2003, rank_2012, rank_2020)] |>
  _[order(clean_name)] |>
# zeige nur die ersten 10, um hier Platz zu sparen
head(10)
```

clean_name	album
<fctr>	<fctr>

1:	AC/DC	Back in Black
2:	Al Green	I'm Still in Love With You
3:	Al Green	Call Me
4:	Beck	Odelay
5:	Bee Gees	Saturday Night Fever: The Original Movie Sound Track
6:	Billy Joel	The Stranger
7:	Black Sabbath	Paranoid
8:	Black Sabbath	Black Sabbath
9:	Bo Diddley	Bo Diddley / Go Bo Diddley
10:	Bob Dylan	John Wesley Harding

	rank_2003	rank_2012	rank_2020
	<int>	<int>	<int>
1:	73	77	84
2:	285	286	306
3:	289	290	427
4:	305	306	424
5:	131	132	163
6:	67	70	169
7:	130	131	139
8:	241	243	355
9:	214	216	455
10:	301	303	337

💡 k) Der Datensatz liegt als `wide.table` vor, da das Ranking für 2003, 2012 und 2020 als Variablen nebeneinander stehen. Wandeln Sie den Datensatz in eine `long.table` (Tidy Data) um, so dass die Rankingangaben in den Variablen `Rang` und `Rangjahr` angegeben sind.

```
# long table mit melt()
long_rs <- melt(rs,
  measure.vars = c("rank_2003", "rank_2012", "rank_2020"),
  variable.name = "Rangjahr",
  value.name = "Rang")
# anzeigen
head(long_rs)
```

	sort_name	clean_name	album	differential
	<fctr>	<fctr>	<fctr>	<int>
1:	Sinatra, Frank	Frank Sinatra	In the Wee Small Hours	-182
2:	Diddley, Bo	Bo Diddley	Bo Diddley / Go Bo Diddley	-241
3:	Presley, Elvis	Elvis Presley	Elvis Presley	-277
4:	Sinatra, Frank	Frank Sinatra	Songs for Swingin' Lovers!	-195
5:	Little Richard	Little Richard	Here's Little Richard	-177
6:	Beyonce	Beyonce	Lemonade	469

	release_year	genre	type	weeks_on_billboard
	<int>	<fctr>	<char>	<int>
1:	1955	Big Band/Jazz	Studio	14
2:	1955	Rock n' Roll/Rhythm & Blues	Studio	NA
3:	1956	Rock n' Roll/Rhythm & Blues	Studio	100
4:	1956	Big Band/Jazz	Studio	NA
5:	1957		Studio	5

```

6:          2016                      Studio                      87
  peak_billboard_position spotify_popularity
      <int>                <int>
1:          2                48
2:        201                50
3:          1                58
4:          2                62
5:         13                64
6:          1                73

      spotify_url artist_member_count artist_gender
      <fctr>                <int>                <fctr>
1: spotify:album:3GmwKB1tgPZgXeRJZSm9WX                1                Male
2: spotify:album:1cbtDEwxCjMhg1b490gNBR                1                Male
3: spotify:album:7GXP50hYyPVLmcVf09Iqin                1                Male
4: spotify:album:4kca7vXd1Wo5GE2DMafvMc                1                Male
5: spotify:album:18tV6PLXYvVjsd0VkoS7M8                1                Male
6: spotify:album:7dK54iZu0xXFarGhXwEXfF                1                Female
  artist_birth_year_sum debut_album_release_year ave_age_at_top_500
      <int>                <int>                <num>
1:        1915                1946                40
2:        1928                1955                27
3:        1935                1956                21
4:        1915                1946                41
5:        1932                1957                25
6:        1981                2003                35

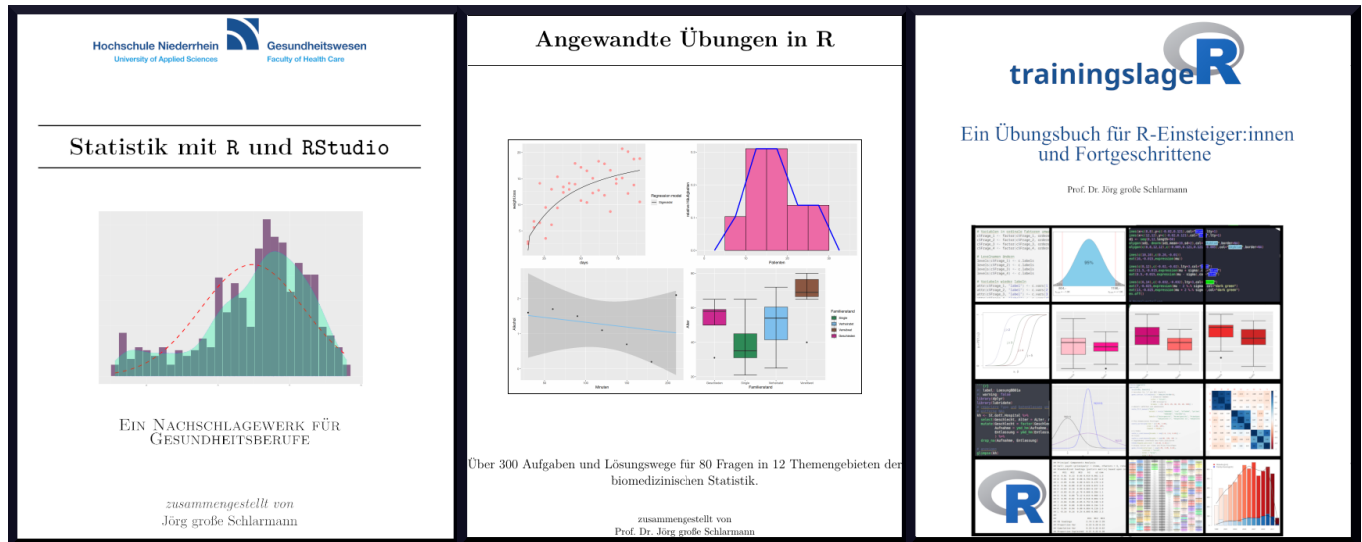
  years_between      album_id  tpye  Rangjahr  Rang
      <int>                <fctr> <fctr>      <fctr> <int>
1:          9 3GmwKB1tgPZgXeRJZSm9WX Studio rank_2003    100
2:          0 1cbtDEwxCjMhg1b490gNBR Studio rank_2003    214
3:          0 7GXP50hYyPVLmcVf09Iqin Studio rank_2003     55
4:         10 4kca7vXd1Wo5GE2DMafvMc Studio rank_2003    306
5:          0 18tV6PLXYvVjsd0VkoS7M8 Studio rank_2003     50
6:         13 7dK54iZu0xXFarGhXwEXfF Studio rank_2003     NA

```

# Literaturverzeichnis

- große Schlarmann, J. (2024a). *Angewandte Übungen in R*. Hochschule Niederrhein. [https://github.com/produnis/angewandte\\_uebungen\\_in\\_R](https://github.com/produnis/angewandte_uebungen_in_R)
- große Schlarmann, J. (2024c). *Statistik mit R und RStudio - Ein Nachschlagewerk für Gesundheitsberufe*. Hochschule Niederrhein. <https://www.produnis.de/R>
- große Schlarmann, J. (2024b). *Statistik mit R und RStudio - Ein Nachschlagewerk für Gesundheitsberufe*. Hochschule Niederrhein. <https://www.produnis.de/R>
- große Schlarmann, J. (2024d). *trainingslageR. Ein Übungsbuch für R-Einsteiger\*innen und Fortgeschrittene*. Hochschule Niederrhein. <https://www.produnis.de/trainingslager>
- Isfort, M., Rottländer, R., Weidner, F., Gehlen, D., Hylla, J., & Tucman, D. (2018). *Pflege-Thermometer 2018 - Eine bundesweite Befragung von Führungskräften zur Situation der Pflege und Patientenversorgung in der stationären Langzeitpflege in Deutschland*. Deutsches Institut für angewandte Pflegeforschung e.V. (DIP).
- Mock, T. (2022). *Tidy Tuesday: A weekly data project aimed at the R ecosystem*. <https://github.com/rfordatascience/tidytuesday>
- R Core Team. (2023). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. <https://www.R-project.org/>
- Walther, B. (2022). *Statistik mit R Schnelleinstieg*. MITP Verlags GmbH.
- Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). *R for Data Science*. O'Reilly Media. <https://r4ds.hadley.nz/>

# Credits



(a) große Schlarmann (2024c)

(a) große Schlarmann (2024a)

(a) große Schlarmann (2024d)



Prof. Dr. Jörg große Schlarmann, BScN, MScN, RN

Hochschule Niederrhein, Krefeld

[joerg.grosseschlarmann@hs-niederrhein.de](mailto:joerg.grosseschlarmann@hs-niederrhein.de)

<https://www.github.com/produnis/tabletrainer>